ACTIVIDAD 4 - DESCRIPCION DE LOS DATOS

Proyecto: Modelo de aprendizaje no supervisado para identificar patrones de viajes en un sistema de transporte masivo mediante K-Means.

1. Fuente de los datos

El proyecto de transporte desarrollado en las actividades anteriores es una simulacion academica y no cuenta con una fuente historica real disponible. Por esta razon se construyo un dataset de muestra de 72 viajes, tal como permite la guia de la actividad cuando no existen fuentes reales accesibles.

Cada fila representa un viaje y contiene variables relacionadas con la demanda y las condiciones del recorrido. El archivo no contiene una etiqueta objetivo, porque el aprendizaje no supervisado busca descubrir agrupaciones a partir de la similitud de los datos.

2. Variables utilizadas

Variable	Tipo	Descripcion
id_viaje	Entero	Identificador consecutivo del viaje.
pasajeros	Entero	Cantidad de pasajeros del recorrido.
numero_paradas	Entero	Numero de paradas realizadas.
transbordos	Entero	Cantidad de cambios o transbordos.
tiempo_estimado	Entero	Duracion estimada del viaje en minutos.
hora_pico	Binaria	1 = hora pico; 0 = fuera de hora pico.

3. Preparacion para el modelo

Las cinco variables numericas se normalizan mediante estandarizacion antes de ejecutar K-Means. Esto evita que una variable con valores numericamente mayores, como pasajeros o tiempo, domine la medida de distancia solo por su escala.

4. Diferencia frente al aprendizaje supervisado

En esta actividad no se utiliza la variable retraso de la actividad anterior. El algoritmo no conoce categorias previas; forma clusters automaticamente y posteriormente se interpretan sus centroides y promedios.

5. Archivo de datos

Nombre: datos_transporte_no_supervisado.csv
Cantidad de registros: 72
Formato: CSV (valores separados por comas).